귀화 여부 예측 모델 정확도 비교

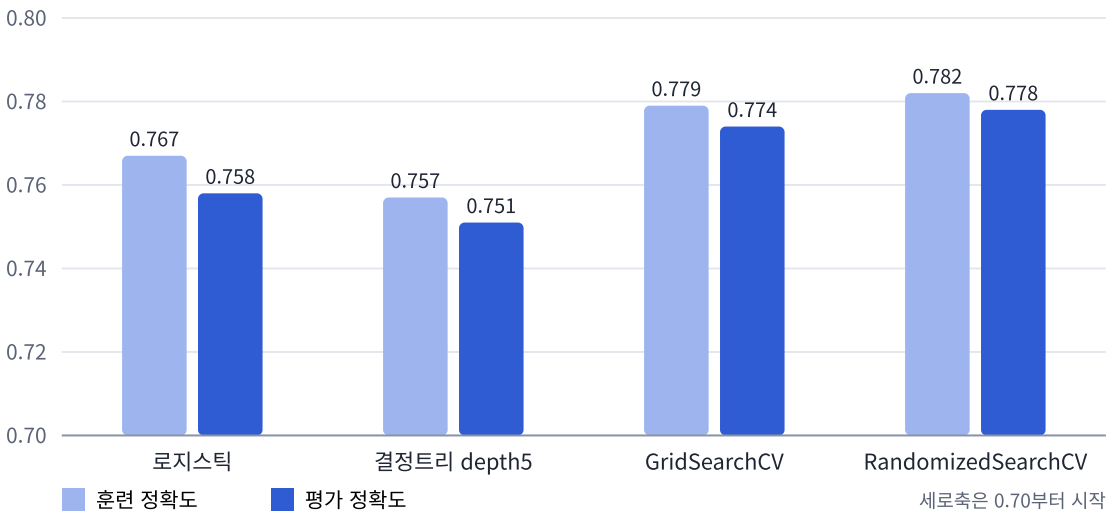
2021 전국다문화가족실태조사 · 외국 출생자 17,933명 (귀화 9,460 / 미귀화 8,473) · 상관 상위 10개 컬럼 · 훈련 80% / 평가 20% · 2026-10-21

최고 평가 정확도
0.778
RandomizedSearchCV 결정트리

최적화로 오른 정확도
+2.7%p
결정트리 depth5 0.751 → 0.778

훈련-평가 차이 (최대)
0.009
모든 모델 과적합 없음

훈련 정확도와 평가 정확도



모델 · 설정	훈련 정확도	평가 정확도	차이
로지스틱 회귀 max_iter=200 · X_train_s로 학습 (수정 후)	0.767*	0.758*	0.009
결정트리 max_depth=5	0.757	0.751	0.006
결정트리 + GridSearchCV depth 11 · impurity 0.0005 · leaf 1	0.779	0.774	0.005
결정트리 + RandomizedSearchCV depth 14 · impurity ≈0.00035 · leaf 2 · split 4	0.782	0.778	0.003

* 로지스틱 회귀는 노트북 16번 셀의 학습·예측 데이터가 맞지 않아(아래 참고), 같은 데이터로 `X_train_s` 로 학습해 다시 계산한 값입니다. 노트북에 출력된 값은 평가 0.76이며 훈련 정확도는 없습니다. 차이는 반올림 전 값으로 계산했습니다. 결정트리 3개 모델의 값은 노트북 출력과 재계산 결과가 소수 넷째 자리까지 일치합니다.

교차검증 정확도 (훈련 데이터 5-fold 평균)

모델	교차검증 정확도
결정트리 `max_depth=5`	0.751 ~ 0.753
GridSearchCV 최적 모델 (140가지 조합)	0.773
RandomizedSearchCV 최적 모델 (50가지 조합)	0.773

GridSearchCV는 섞어서 나눈 5-fold(`StratifiedKFold(shuffle=True)`), RandomizedSearchCV는 `cv=5` (섞지 않음)를 써서 두 값은 나누는 방식이 조금 다릅니다.

정리

가장 좋은 모델은 RandomizedSearchCV로 찾은 결정트리입니다. 평가 정확도 0.778로 처음 결정트리(0.751)보다 2.7%p 높고, GridSearchCV보다 적은 조합으로 비슷하거나 더 좋은 값을 찾았습니다.

- **과적합이 없습니다.** 모든 모델의 훈련-평가 차이가 0.009 이하라 처음 보는 데이터에도 비슷하게 맞힙니다.
- **최적화 효과는 2~3%p 수준입니다.** 컬럼이 10개로 제한돼 있어 모델만 바꿔서는 크게 오르기 어렵습니다. 별도 실험(HistGradientBoosting, 가구 그룹 5-fold)에서 배우자 정보(나이차, 배우자 한국 출생 여부, 자녀수 등)를 추가하자 AUC가 0.862 → 0.876으로 올랐듯이, 컬럼을 늘리는 쪽이 효과가 큽니다.

노트북에서 확인할 점

노트북 출력이 코드와 맞지 않는 셀이 있습니다. 크기를 맞춘 데이터로 학습한 결정트리에 원래 값을 넣으면 정확도가 0.53 수준으로 떨어져야 하는데(재현 결과), 노트북의 21·22번, 44~47번, 55·56번 셀은 원래 값과 크기 맞춘 값에서 같은 점수가 출력됐습니다. 셀을 순서와 다르게 실행했거나 이전 실행 결과가 남아 있는 것으로 보입니다. **런타임 → 모두 실행**으로 한 번 다시 확인하세요.

로지스틱 회귀의 0.76은 다시 확인이 필요합니다. 16번 셀은 `X_train` (원래 값)으로 학습하고 17번 셀은 `X_test_s` (크기 맞춘 값)로 예측합니다. 코드대로라면 맞지 않는 조합이라, 위 표에는 `model.fit(X_train_s, y_train)` 으로 고친 값(평가 0.758)을 넣었습니다.

32·33번 셀은 다른 모델의 점수입니다. `cross` 를 학습시키고 `dt.score(...)` 로 점수를 내서 이 표에서 제외했습니다.